

Predicción de Calidad del Vino mediante Aprendizaje Automático

Mateo Diaz
Universidad San Francisco de Quito
Ingeniería en Ciencias de la Computación
Aprendizaje Automático
Quito, Ecuador

Resumen—Este informe presenta el desarrollo de un pipeline de aprendizaje automático para predecir la calidad del vino a partir de variables fisicoquímicas. El proyecto sigue una arquitectura reproducible en Python, separando análisis exploratorio de datos, preprocesamiento, entrenamiento, ajuste de hiperparámetros, evaluación final e inferencia. Se comparan modelos lineales regularizados, árboles de decisión, bosques aleatorios, máquinas de soporte vectorial y una red neuronal pequeña. La evaluación se realiza mediante validación cruzada sobre el conjunto de entrenamiento y una evaluación final sobre un conjunto de prueba reservado. Los resultados permiten analizar el desempeño predictivo del modelo y discutir su utilidad como herramienta de apoyo para productores de vino.

Index Terms—Aprendizaje automático, regresión, Wine Quality, validación cruzada, regularización, Random Forest, SVR, redes neuronales.

Tabla I: Variables principales del conjunto de datos Wine Quality.

Variable	Descripción general
fixed acidity	Acidez fija
volatile acidity	Acidez volátil
citric acid	Ácido cítrico
residual sugar	Azúcar residual
chlorides	Cloruros
free sulfur dioxide	Dióxido de azufre libre
total sulfur dioxide	Dióxido de azufre total
density	Densidad
pH	Nivel de pH
sulphates	Sulfatos
alcohol	Porcentaje de alcohol
quality	Variable objetivo

I. INTRODUCCIÓN

La calidad del vino depende de múltiples factores químicos y sensoriales. En este proyecto se utiliza el conjunto de datos *Wine Quality* de UCI para construir modelos capaces de estimar la variable *quality* a partir de mediciones como alcohol, pH, sulfatos, acidez volátil y otros atributos fisicoquímicos. El objetivo no es reemplazar la evaluación experta, sino construir una herramienta de apoyo que permita identificar patrones asociados con vinos de mayor o menor calidad.

El problema se modela inicialmente como una tarea de regresión, debido a que la variable objetivo *quality* es numérica y ordinal. Esta decisión permite evaluar el error promedio en puntos de calidad mediante métricas como RMSE y MAE. Sin embargo, también se reconoce que la calidad corresponde a una calificación discreta, por lo que una alternativa válida sería formular el problema como clasificación multiclase o binaria. En este informe se mantiene la formulación de regresión para conservar la información ordinal de la variable.

II. DESCRIPCIÓN DEL CONJUNTO DE DATOS

El conjunto de datos contiene observaciones de vinos descritos por variables fisicoquímicas. La variable objetivo es *quality*, que representa una calificación asignada al vino. Las variables predictoras se resumen en la Tabla I.

III. ANÁLISIS EXPLORATORIO DE DATOS

El análisis exploratorio de datos se realizó para comprender la distribución de la variable objetivo, detectar posibles desequilibrios, inspeccionar variables relevantes y observar relaciones entre predictores. En particular, se estudiaron pH, sulphates, alcohol y volatile acidity, debido a su relevancia en la caracterización química del vino.

III-A. Distribución de la variable objetivo

La Figura 1 muestra la distribución de la calidad del vino. Se espera que la mayoría de observaciones se concentre en calificaciones medias, mientras que las calificaciones extremas suelen aparecer con menor frecuencia. Este comportamiento es importante porque los modelos pueden aprender mejor los valores frecuentes y cometer mayores errores en calidades poco representadas.




Figura 1: Distribución de la variable objetivo `quality`.

III-B. Variables fisicoquímicas relevantes

Las Figuras 2–5 muestran la relación entre variables clave y la calidad del vino. En general, el alcohol tiende a ser una variable altamente informativa, mientras que la acidez volátil suele presentar una relación negativa con la calidad. Los sulfatos pueden mostrar una asociación positiva moderada, mientras que el pH puede no separar de forma tan clara los niveles de calidad.




Figura 2: Distribución de alcohol según calidad del vino.




Figura 3: Distribución de acidez volátil según calidad del vino.




Figura 4: Distribución de sulfatos según calidad del vino.




Figura 5: Distribución de pH según calidad del vino.

III-C. Correlación entre variables

La matriz de correlación permite revisar relaciones lineales entre variables y detectar posibles problemas de multicolinealidad. Esto es relevante para modelos lineales regularizados como Ridge, Lasso y Elastic Net. Lasso puede seleccionar una sola variable entre predictores altamente correlacionados, mientras que Elastic Net tiende a ser más estable al combinar penalización L1 y L2.




Figura 6: Matriz de correlación de las variables numéricas.

IV. PREPROCESAMIENTO

El preprocesamiento se implementó mediante Pipeline de scikit-learn para evitar fuga de información. Todas las transformaciones se ajustan únicamente sobre los datos de entrenamiento dentro de cada partición de validación cruzada.

Como el conjunto de datos contiene variables numéricas, no se requiere codificación de variables categóricas. Se aplica estandarización mediante StandardScaler, especialmente importante para Ridge, Lasso, Elastic Net, SVR y redes neuronales, ya que estos modelos son sensibles a la escala de las variables.

Tabla II: Diseño del pipeline de aprendizaje automático.

Etapas	Descripción
Carga de datos	Lectura del archivo CSV original
Separación	División entre X y y
Train/Test split	Reserva de conjunto de prueba intacto
Preprocesamiento	Estandarización de variables numéricas
Selección de modelo	Validación cruzada k -fold
Tuning	Búsqueda de hiperparámetros con GridSearchCV
Evaluación final	Métricas sobre test set reservado
Inferencia	Interpretación y ejemplos de predicción

V. MODELOS COMPARADOS

Se compararon modelos con diferentes niveles de flexibilidad e interpretabilidad:

- **Ridge Regression:** regresión lineal con penalización L2, útil ante multicolinealidad.
- **Lasso:** regresión lineal con penalización L1, útil para selección de variables.
- **Elastic Net:** combina penalización L1 y L2, usualmente más estable con predictores correlacionados.
- **Decision Tree:** modelo no lineal e interpretable, aunque propenso al sobreajuste.
- **Random Forest:** ensamble de árboles que reduce varianza mediante promediado.
- **SVR:** máquina de soporte vectorial para regresión, capaz de modelar relaciones no lineales con kernels.
- **MLPRegressor:** red neuronal pequeña utilizada como referencia no lineal.

La selección de modelos se realizó mediante validación cruzada sobre el conjunto de entrenamiento. El conjunto de prueba se mantuvo reservado hasta la evaluación final.

VI. DISEÑO EXPERIMENTAL

El flujo experimental se resume de la siguiente manera:

1. Dividir los datos en entrenamiento y prueba.
2. Ajustar preprocesamiento y modelo dentro de un Pipeline.
3. Comparar modelos base con validación cruzada.
4. Ajustar hiperparámetros mediante GridSearchCV.
5. Seleccionar el modelo con menor RMSE promedio en validación cruzada.
6. Evaluar una sola vez el mejor modelo sobre el test set final.

Las métricas utilizadas fueron RMSE, MAE y R^2 . RMSE penaliza más los errores grandes; MAE expresa el error promedio en puntos de calidad; y R^2 mide la proporción de variabilidad explicada.

VII. RESULTADOS

La Tabla III debe completarse con los valores generados en results/tuned_model_comparison.csv. Esta tabla resume la comparación de modelos tuneados mediante validación cruzada.

Tabla III: Comparación de modelos tuneados mediante validación cruzada. Completar con results/tuned_model_comparison.csv.

Modelo	RMSE CV	MAE CV	R^2 CV
Ridge	–	–	–
Lasso	–	–	–
Elastic Net	–	–	–
Decision Tree	–	–	–
Random Forest	–	–	–
SVR	–	–	–
Neural Network	–	–	–

La evaluación final del mejor modelo se presenta en la Tabla IV. Estos valores deben tomarse de results/evaluation_metrics.csv o results/tuned_final_test_metrics.csv.

Tabla IV: Métricas finales sobre el test set reservado. Completar con results/evaluation_metrics.csv.

Métrica	Valor
RMSE	–
MAE	–
R^2	–

VII-A. Diagnóstico de predicciones

La Figura 7 compara valores reales y predichos. Una predicción ideal se ubicaría cerca de la línea diagonal. La Figura 8 muestra los residuos frente a las predicciones; idealmente, los residuos deberían distribuirse alrededor de cero sin patrones sistemáticos. Finalmente, la Figura 9 muestra la distribución de errores.

VII-B. Importancia de variables

Si el mejor modelo permite interpretación directa, como Random Forest o un modelo lineal, se reporta la importancia de variables. En caso de que el mejor modelo sea SVR con kernel no lineal o una red neuronal, la interpretación directa es limitada y debe complementarse con el EDA, la matriz de correlación y modelos interpretables.




Figura 7: Valores reales vs. valores predichos en el test set.




Figura 8: Residuos frente a predicciones.




Figura 9: Distribución de errores de predicción.




Figura 10: Importancia de variables del modelo final, si está disponible.

VIII. DISCUSIÓN

Los resultados deben interpretarse considerando que la calidad del vino es una evaluación sensorial y subjetiva. Aunque las variables químicas contienen información relevante, no capturan por completo la percepción humana. Por esta razón, el modelo debe entenderse como una herramienta de apoyo y no como un reemplazo de catadores expertos.

Desde el punto de vista metodológico, la comparación entre Lasso y Elastic Net es importante. Lasso puede generar modelos más dispersos al forzar coeficientes a cero, pero su selección puede ser inestable cuando existen predictores correlacionados. Elastic Net suele ofrecer mayor estabilidad al combinar la selección de variables de Lasso con la regularización L2 de Ridge.

En términos de negocio, variables como alcohol, acidez volátil, sulfatos y pH pueden ser monitoreadas por productores para identificar perfiles químicos asociados con mejores calificaciones. Sin embargo, las asociaciones encontradas por los modelos no deben interpretarse como causalidad directa.

IX. EJEMPLOS DE PREDICCIÓN

El archivo `results/final_predictions.csv` contiene ejemplos de predicción generados por el modelo final. La Tabla V muestra el formato sugerido para reportar algunos casos.

Tabla V: Ejemplos de predicción. Completar con `results/final_predictions.csv`.

Muestra	Calidad real	Predicción	Error absoluto
1	—	—	—
2	—	—	—
3	—	—	—
4	—	—	—
5	—	—	—

X. CONCLUSIONES

Este proyecto implementó un pipeline completo y reproducible para predecir la calidad del vino mediante aprendizaje

automático. Se realizó EDA, preprocesamiento con control de fuga de información, comparación de modelos, ajuste de hiperparámetros y evaluación final sobre un conjunto de prueba reservado.

La formulación como regresión permite interpretar los errores en puntos de calidad, lo cual es útil para una aplicación práctica. Los resultados pueden apoyar el control de calidad en la industria vinícola, especialmente al identificar variables químicas asociadas con mejores o peores predicciones. Como trabajo futuro, se podría comparar formalmente la formulación de regresión con clasificación binaria o multiclase, además de incorporar técnicas de explicación como permutation importance o SHAP.

REPRODUCIBILIDAD

El proyecto se organizó con una arquitectura limpia en GitHub. Los scripts principales son:

- `src/eda.py`: genera análisis exploratorio y figuras.
- `src/train.py`: entrena modelos base con validación cruzada.
- `src/tune.py`: ajusta hiperparámetros con `GridSearchCV`.
- `src/evaluate.py`: evalúa el mejor modelo en el test set final.
- `src/predict.py`: genera ejemplos de predicción.

Para reproducir el proyecto:

```
python src/eda.py
python src/train.py
python src/tune.py
python src/evaluate.py
python src/predict.py
```

REFERENCIAS

- [1] P. Cortez, A. Cerdeira, F. Almeida, T. Matos, and J. Reis, "Modeling wine preferences by data mining from physicochemical properties," *Decision Support Systems*, vol. 47, no. 4, pp. 547–553, 2009.
- [2] G. James, D. Witten, T. Hastie, R. Tibshirani, and J. Taylor, *An Introduction to Statistical Learning: With Applications in Python*. Springer, 2023.
- [3] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed. Springer, 2009.
- [4] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [5] A. E. Hoerl and R. W. Kennard, "Ridge regression: Biased estimation for nonorthogonal problems," *Technometrics*, vol. 12, no. 1, pp. 55–67, 1970.
- [6] R. Tibshirani, "Regression shrinkage and selection via the lasso," *Journal of the Royal Statistical Society: Series B*, vol. 58, no. 1, pp. 267–288, 1996.
- [7] H. Zou and T. Hastie, "Regularization and variable selection via the elastic net," *Journal of the Royal Statistical Society: Series B*, vol. 67, no. 2, pp. 301–320, 2005.
- [8] L. Breiman, "Random forests," *Machine Learning*, vol. 45, pp. 5–32, 2001.
- [9] C. Cortes and V. Vapnik, "Support-vector networks," *Machine Learning*, vol. 20, pp. 273–297, 1995.